

Redes Veiculares com Drones para detecção de Estresse Hídrico

Eduardo Costa Resende & Paulo Otavio Luczensky de Souza

Abstract— Brazil stands out as one of the world's leading agricultural producers, driven by its territorial diversity, abundant water resources, and technological advances in the sector. However, irregular rainfall and the increasing occurrence of water stress—especially in the Central-West and Northeast regions—make artificial irrigation essential to maintain crop productivity. Systems such as center pivots are widely used, but their operation may present failures that compromise the uniformity of water application, resulting in significant yield losses. Studies show that areas irrigated with low uniformity can experience productivity reductions of up to 10%, highlighting the importance of precise monitoring. In this context, drone-based technologies have proven promising for mapping water stress and identifying spatial variations associated with irrigation system defects. Thus, this work proposes a vehicular drone network aimed at detecting water stress in near real time, contributing to more efficient diagnostics, waste reduction, and improved maintenance of center-pivot systems.

Index Terms— Vehicular Networks, Drones, Water Stress, Irrigation

Resumo— O Brasil destaca-se como um dos maiores produtores agrícolas do mundo, impulsionado por sua diversidade territorial, abundância de recursos hídricos e avanços tecnológicos no setor. Entretanto, a irregularidade das chuvas e a crescente ocorrência de estresse hídrico, especialmente nas regiões Centro-Oeste e Nordeste, tornam a irrigação artificial indispensável para manter a produtividade das lavouras. Sistemas como pivôs centrais são amplamente utilizados, mas sua operação pode apresentar falhas que comprometem a uniformidade da aplicação de água, resultando em perdas significativas de rendimento. Estudos demonstram que áreas irrigadas com baixa uniformidade podem sofrer reduções de até 10% na produtividade, evidenciando a importância de monitoramento preciso. Nesse contexto, tecnologias baseadas em drones têm se mostrado promissoras para mapear o estresse hídrico e identificar variações espaciais associadas a defeitos no sistema de irrigação. Assim, este trabalho propõe uma rede veicular de drones voltada à detecção de estresse hídrico em tempo quase real, contribuindo para diagnósticos mais eficientes, redução de desperdícios e aprimoramento da manutenção de pivôs centrais.

Palavras Chave— Redes Veiculares, Drones, Estresse Hídrico, Irrigação

I. INTRODUÇÃO

Ao longo de sua história, o Brasil consolidou-se como um dos principais protagonistas da produção agrícola mundial. Seu vasto território, marcado por uma ampla variedade de solos e condições climáticas favoráveis, aliado à abundância de recursos hídricos e ao contínuo avanço tecnológico no setor, tem impulsionado a produtividade e fortalecido a competitividade do país no mercado internacional.

Em 2020, estudos da Organização das Nações Unidas para Alimentação e Agricultura (FAO, do inglês *Food and Agriculture Organization*) estimaram que o Brasil teria capacidade para

alimentar aproximadamente 628,223 milhões de pessoas [1]. Isso indica que, além de suprir a demanda interna de seus 212 milhões de habitantes, o país também seria capaz de prover alimento para outras 410 milhões de pessoas exclusivamente por meio de suas exportações.

A Tabela I apresenta os estudos da FAO, com relação ao número de pessoas alimentadas pela agricultura brasileira, em comparação com a população mundial.

TABELA I
POPULAÇÃO MUNDIAL E POPULAÇÃO ALIMENTADA PELO BRASIL*

Ano	População Mundial	População Alimentada pelo Brasil
2011	7.002.860.604	392.690.531
2012	7.085.763.408	412.948.359
2013	7.169.640.142	451.228.452
2014	7.254.228.377	462.582.206
2015	7.338.964.960	504.665.028
2016	7.424.282.488	424.190.465
2017	7.509.065.951	550.610.529
2018	7.591.932.907	536.985.275
2019**	7.673.533.972	611.498.666
2020**	7.755.567.903	628.222.978

* Produtos: Arroz, Cevada, Milho, Soja e Trigo.

** Estimativas.

Apesar da alta produtividade agrícola, a irrigação nem sempre ocorre de forma natural, como pelas chuvas, o que favorece o surgimento do estresse hídrico. Esse fenômeno ocorre quando a água disponível no solo não é suficiente para atender às necessidades metabólicas e fisiológicas das plantas, ou seja, quando a demanda hídrica supera a oferta. No Brasil, as regiões Centro-Oeste e Nordeste são as mais afetadas pelo estresse hídrico devido às secas recorrentes e à baixa disponibilidade de recursos hídricos, fatores que impactam diretamente a produção agrícola. Além delas, partes das regiões Sul e Sudeste também vêm enfrentando escassez de água, sobretudo em períodos de estiagem prolongada.

Para mitigar esses impactos, produtores rurais adotam sistemas automatizados de irrigação, como pivôs centrais e gotejamento, buscando garantir que as lavouras recebam água de forma adequada. Contudo, mesmo sistemas mecanizados não asseguram irrigação totalmente homogênea: pivôs podem apresentar vazamentos, falhas em válvulas, variações de pressão ou serem afetados por irregularidades do terreno. Assim, após a irrigação, podem surgir áreas com déficit ou excesso de água.

No experimento descrito por [2], a porção do pivô com menor uniformidade de aplicação (CUH = 65%), correspondente à área atendida pelo *end gun* (tratamento EG), apresentou rendimento de trigo de inverno aproximadamente 10% inferior às áreas com

melhor uniformidade (CUH entre 78% e 89%, tratamentos RS e DS).

TABELA II
COEFICIENTES DE UNIFORMIDADE (CUH E CUC) PARA DIFERENTES ÁREAS IRRIGADAS NO SISTEMA DE PIVÔ CENTRAL.

k (%)	Posição	Tipo de aspersor	CUH (%)	CUC (%)
20	Primeiro lance	R3000	89	96
	Segundo lance	D3000	81	95
	Canhão	P85A	67	88
40	Primeiro lance	R3000	86	93
	Segundo lance	D3000	78	91
	Canhão	P85A	63	86

k : valor percentual do temporizador; CUH: coeficiente de uniformidade de aplicação de água ao longo da direção radial do pivô; CUC: coeficiente de uniformidade de aplicação de água ao longo da direção de deslocamento do pivô.

A tabela acima apresenta os coeficientes de uniformidade para diferentes áreas irrigadas pelo sistema de pivô central, considerando duas velocidades de deslocamento. O aspersor R3000 obteve os maiores valores de CUH e CUC, seguido pelo modelo D3000, enquanto o aspersor de impacto P85A registrou os menores índices. Observa-se também que, para ambas as velocidades, a variação de CUH entre as posições foi muito maior que a de CUC. Além disso, o aumento da velocidade de deslocamento produziu efeitos semelhantes em ambos os coeficientes, reduzindo-os de 2 a 4 pontos percentuais quando o ajuste do temporizador passou de 20% para 40%.




Fig. 1. Arranjo da área experimental irrigada por pivô central [3].

A figura ilustra o arranjo da área experimental irrigada por pivô central, correspondente a um setor de 1/8 de círculo. Os diferentes trechos do equipamento (*first span*, *second span* e faixa do *end gun*) são indicados com seus comprimentos em metros e diferenciados pelas tonalidades, que representam os emissores R3000, D3000 e o canhão P85A. Os três retângulos brancos em cada faixa correspondem às parcelas experimentais de 6 m x 10 m, utilizadas como repetições para avaliar biomassa, produtividade de grãos e demais variáveis associadas aos coeficientes de uniformidade apresentados na Tabela 2 [3].

Estudos anteriores demonstram que drones equipados com sensores multiespectrais são capazes de mapear o estresse hídrico em culturas irrigadas por pivô central, gerando mapas de índices como o CWSI e identificando variações espaciais associadas a déficits de irrigação [4]. Contudo, essas abordagens

são, em geral, empregadas de forma pontual e *offline*, sem uma infraestrutura de comunicação que integre o VANT, os equipamentos de irrigação e demais nós da fazenda.

Diante desse cenário, o presente estudo propõe o desenvolvimento de uma rede veicular baseada em drones capaz de identificar pontos de estresse hídrico, permitindo localizar áreas problemáticas e auxiliar na detecção de falhas que demandam manutenção no sistema de irrigação.

II. REFERENCIAL TEÓRICO

A irrigação desempenha papel central na manutenção da produtividade agrícola em regiões sujeitas à escassez hídrica. Entretanto, mesmo sistemas automatizados, como pivôs centrais, podem apresentar falhas que comprometem a distribuição uniforme de água, gerando áreas com déficit ou excesso de irrigação. Esse contexto tem motivado o desenvolvimento de abordagens que combinem sensoriamento remoto, Internet das Coisas (IoT, do inglês *Internet of Things*) e análise inteligente de dados para monitorar o estado hídrico das culturas e apoiar o manejo da irrigação. Nesta seção, são apresentados trabalhos que abordam: (i) os efeitos da uniformidade de aplicação em pivôs centrais, (ii) o uso de VANTs para detecção de estresse hídrico e (iii) o emprego de sensoriamento multiespectral e índices espectrais na caracterização do estresse hídrico em milho irrigado.

1. **Effects of water application uniformity using a center pivot on winter wheat yield, water and nitrogen use efficiency in the North China Plain [3]:** o artigo avalia como diferentes níveis de uniformidade de aplicação de água, obtidos por meio de variações em emissores e velocidades de deslocamento de um pivô central, impactam o rendimento do trigo de inverno e a eficiência de uso de água e nitrogênio. Os autores mostram que áreas atendidas por trechos com menor uniformidade (por exemplo, CUH em torno de 65%, associado ao *end gun*) apresentam reduções de rendimento da ordem de 10% em relação a setores com melhor desempenho hidráulico (CUH entre 78% e 89%). Esses resultados reforçam que falhas na distribuição espacial da lâmina aplicada podem comprometer a produtividade mesmo quando o volume total de água é mantido constante, evidenciando a importância de monitorar e corrigir problemas de uniformidade em sistemas de pivô central.
2. **Remote Sensing Using Unmanned Aerial Vehicles for Water Stress Detection: A Review Focusing on Specialty Crops [5]:** o artigo apresenta uma revisão abrangente sobre o uso de VANTs em agricultura de precisão, com ênfase na detecção de estresse hídrico em culturas de alto valor. São discutidos tipos de plataformas (multirrotores e asas fixas), sensores ópticos e termais, estratégias de planejamento de voo e técnicas de processamento de imagens. Os autores destacam que VANTs permitem obter dados de alta resolução espacial e temporal, superando limitações de sensoriamento orbital e de medições pontuais em campo. A revisão também aponta desafios relacionados à autonomia de voo, às regulamentações e à necessidade de integração dos mapas gerados com sistemas de

apoio à decisão. Esse panorama sustenta o uso de drones como componente central em arquiteturas voltadas ao monitoramento hídrico de áreas irrigadas.

3. **Crop water stress detection based on UAV remote sensing systems [6]:** o artigo discute o uso de sistemas de sensoriamento remoto embarcados em VANTs para detecção de estresse hídrico em culturas agrícolas. São avaliadas diferentes combinações de sensores ópticos e termais, estratégias de processamento de imagens e índices espectrais relacionados ao estado hídrico das plantas. O estudo mostra que mapas derivados de VANTs permitem capturar a variabilidade intra-talhão do estresse hídrico com maior detalhamento do que métodos tradicionais baseados apenas em medições pontuais de umidade ou de potencial hídrico. Os autores também discutem desafios ligados à calibração dos sensores, à padronização dos índices utilizados e à integração com informações de manejo. Essas evidências reforçam a viabilidade de utilizar produtos de VANTs como entrada para sistemas de decisão em irrigação.

4. **Mapping Maize Water Stress Based on UAV Multispectral Remote Sensing [4]:** o artigo investiga a detecção de estresse hídrico em milho irrigado por pivô central por meio de sensoriamento remoto embarcado em VANTs. Os autores utilizam um drone equipado com câmera multiespectral para adquirir imagens de alta resolução do dossel em diferentes estádios de desenvolvimento da cultura e sob distintos níveis de déficit de irrigação. A partir dessas imagens são calculados diversos índices de vegetação, como TCARI/RDVI e TCARI/SAVI, que são relacionados, por meio de modelos empíricos de regressão, ao *Crop Water Stress Index* (CWSI) obtido em medições de campo. Os resultados indicam forte associação entre os índices espectrais e o CWSI, permitindo a geração de mapas espaciais de estresse hídrico que evidenciam a variabilidade intra-talhão decorrente das diferentes lâminas aplicadas pelo pivô. Esse trabalho fornece uma referência direta para o tipo de produto esperado na arquitetura proposta neste artigo, em que mapas de estresse hídrico são integrados a dados operacionais dos pivôs para apoiar o manejo da irrigação.

III. METODOLOGIA

Neste tópico, são detalhados os processos de implementação do sistema proposto. Para uma melhor organização e clareza, a seção é estruturada em subtópicos, cada um dedicado a uma etapa específica do desenvolvimento. Inicialmente, apresenta-se a arquitetura implementada; em seguida, descrevem-se o emprego dos drones e o funcionamento dos pivôs centrais, bem como sua operação integrada. Por fim, discute-se, de forma técnica, os principais riscos de segurança associados ao processo de comunicação entre esses componentes, destacando potenciais vulnerabilidades e suas implicações no desempenho do sistema.

A. Arquitetura do Projeto

Esta seção tem como objetivo apresentar a Arquitetura do Sistema, descrevendo de forma clara o fluxo completo de funcionamento da solução.

A seguir, apresenta-se a figura que sintetiza todo o funcionamento da arquitetura proposta.




Fig. 2. Arquitetura proposta para a implementação do sistema de detecção de estresse hídrico com drones e pivôs centrais.

Inicialmente, um ou mais drones realizam a coleta de dados sobre as áreas monitoradas, adquirindo imagens RGB, multiespectrais e termais que auxiliam na detecção de regiões com potencial estresse hídrico. Em paralelo, os módulos instalados nos pivôs registram continuamente informações operacionais, como vazão, pressão, velocidade de deslocamento e posição angular. Em seguida, os dados provenientes dos drones e dos pivôs são integrados, permitindo uma visão conjunta do estado hídrico da cultura e das condições de operação do sistema de irrigação.

Além disso, o módulo do pivô registra continuamente informações operacionais de todo o sistema de irrigação, como vazão, pressão, velocidade de deslocamento e posição angular. Esses mesmos parâmetros também podem ser coletados pelo drone, ampliando a consistência e a redundância dos dados monitorados.

Os dados adquiridos pelo drone são então enviados a uma plataforma de processamento, onde são analisados com o objetivo de subsidiar melhorias operacionais, como o ajuste da lâmina de água, a adequação da velocidade de rotação do pivô e outras variáveis de controle do sistema de irrigação.

Por fim, após o processamento, as recomendações são transmitidas ao drone, que atua como agente responsável por enca-

minhar os comandos a cada pivô avaliado. Esse fluxo cria um ciclo integrado e inteligente de monitoramento, diagnóstico e intervenção, otimizando o uso de recursos hídricos, aumentando a eficiência operacional e contribuindo para uma irrigação mais precisa e sustentável.

B. Drones

Na arquitetura proposta, prevê-se o uso de drones multirrotor profissionais, equipados com piloto automático e Sistema Global de Navegação por Satélite (GNSS, do inglês *Global Navigation Satellite System*), preferencialmente RTK, capazes de realizar voo estacionário. A adoção desse tipo de plataforma segue configurações amplamente descritas na literatura [7, 8], que evidenciam sua facilidade de manobra sobre áreas circulares de pivôs centrais e a capacidade de voar em baixa altitude com alta sobreposição de imagens. De forma consistente com esses trabalhos, consideram-se planos de voo com altitudes entre 70 e 120 m, sobreposição frontal e lateral em torno de 75 a 80% e janelas de aquisição entre 10h e 14h.

O sistema embarcado contou com três sensores principais: (i) uma câmera RGB de alta resolução, usada para gerar mosaicos georreferenciados e modelos de superfície; (ii) uma câmera multiespectral (bandas azul, verde, vermelho, red edge e NIR), que permite calcular índices de vegetação e indicadores de estado hídrico, como NDVI e NDRE [7, 9]; (iii) um sensor termal (8–14 μm), utilizado para estimar a temperatura do dossel e calcular índices de estresse, como o CWSI [7, 9].

Os voos foram planejados em softwares específicos, com altitudes entre 70 e 120 m e sobreposição frontal e lateral de 75 a 80%, garantindo boa qualidade na reconstrução das imagens [7]. As coletas ocorreram preferencialmente entre 10h e 14h, período que reduz variações de luz e aumenta a sensibilidade da câmera térmica para identificar estresse hídrico.

Após o voo, os dados passaram por etapas de processamento que incluíram calibração radiométrica, ortorretificação e geração de mosaicos. Também foram produzidos mapas de temperatura de superfície e índices espectrais relacionados ao estresse hídrico, com parametrizações compatíveis com estudos de irrigação de precisão [7, 10]. Esses produtos foram georreferenciados e divididos conforme a estrutura do pivô, permitindo calcular métricas médias por lance ou setor angular, seguindo práticas comuns em análises de uniformidade usando imagens de drones [9].

C. Pivôs

Na solução proposta, os pivôs são equipados com sensores que registram, de forma contínua, informações relevantes para acompanhar o funcionamento da irrigação. Entre esses dados estão a posição angular, a velocidade de avanço, a pressão de operação e a vazão total, variáveis consideradas essenciais em sistemas modernos de monitoramento de pivôs [11].

A posição angular foi obtida por meio de encoders instalados no ponto central ou por GNSS colocado no último vão. Essa abordagem é semelhante à utilizada em soluções comerciais que empregam LoRaWAN para rastrear a posição e o estado do pivô [11]. A partir dessa posição, calcula-se também a velocidade de avanço, que é fundamental para estimar a lâmina aplicada em cada parte do círculo irrigado.

A pressão da água foi medida por sensores instalados na entrada do pivô e, em alguns casos, também em trechos intermediários. Já a vazão foi monitorada por medidores eletromagnéticos ou ultrassônicos. O objetivo é identificar variações no sistema hidráulico que possam indicar falhas, garantindo maior segurança e eficiência à operação [12, 13].

Todos esses dados foram reunidos em uma unidade de controle baseada em microcontrolador ou CLP, que integra as medições, registra as séries temporais e envia as informações para o servidor em nuvem. Essa unidade funciona de maneira semelhante às central node boards utilizadas em sistemas avançados de manutenção inteligente de pivôs.

D. Solução

A solução proposta organiza o fluxo de operação em três grandes etapas, ilustradas na Figura 2: (i) aquisição de dados pelos drones sobre diferentes pivôs; (ii) processamento centralizado e apoio à decisão em uma plataforma computacional; e (iii) envio das recomendações de irrigação de volta aos pivôs monitorados. Essa estrutura segue modelos consolidados de irrigação de precisão que combinam sensoriamento remoto, telemetria de campo e módulos de controle orientados por dados [7, 10, 12, 14].

Na etapa de coleta, um ou mais drones executam missões planejadas sobre o conjunto de pivôs (Pivô 1, Pivô 2, ..., Pivô N), registrando imagens RGB, multiespectrais e termais de toda a área irrigada. Esses dados permitem gerar produtos como mapas georreferenciados, de vegetação e de estresse hídrico, associados individualmente a cada pivô, em linha com abordagens de mapeamento de uniformidade descritas na literatura [7, 9]. Quando necessário, uma segunda missão (Drone 2) pode ser realizada com foco em setores específicos previamente identificados como críticos, refinando o diagnóstico em áreas com maior risco de estresse ou possíveis falhas de aplicação.

Em seguida, todas as informações provenientes dos drones e dos módulos dos pivôs são integradas na plataforma de processamento. Nela, os dados são armazenados, organizados e combinados por meio de algoritmos que relacionam índices espectrais e indicadores de estresse hídrico com as condições operacionais do pivô (posição angular, velocidade, pressão e vazão). Esse cruzamento permite estimar, para cada setor do círculo irrigado, a lâmina efetivamente aplicada e o estado hídrico da cultura [7, 10, 12]. A plataforma então consolida essas informações em indicadores por pivô, como setores sub ou superirrigados, padrões de uniformidade e evolução do estresse ao longo dos ciclos.

Por fim, o módulo de decisão sintetiza todos os resultados e gera recomendações de manejo para cada pivô monitorado. As orientações podem incluir ajustes de velocidade, redefinição da lâmina alvo por setor ou priorização de pivôs mais críticos em situações de restrição hídrica, de acordo com práticas de irrigação de precisão baseadas em IoT e aprendizado de máquina [12, 14]. Essas recomendações são então enviadas ao campo, seja como comandos diretos para o controlador do pivô (quando há integração com o sistema de automação), seja como instruções exibidas em uma interface web ou aplicativo. Dessa forma, o ciclo completo realiza o monitoramento e

análise, permitindo que diversos pivôs sejam acompanhados e ajustados de forma coordenada e eficiente.




Fig. 3. Mapa de estresse hídrico (CWSI) do milho no estágio reprodutivo (DOY 231) em área irrigada por pivô central, destacando os tratamentos TRT1–TRT5.




Fig. 4. Mapa de estresse hídrico (CWSI) do mesmo talhão em data posterior (DOY 240), evidenciando a evolução temporal do estresse e as zonas de manejo associadas aos tratamentos TRT1–TRT5.

Na Figura 3, adaptada de Zhang et al. [4], apresenta-se o mapa de estresse hídrico do milho no estágio reprodutivo (DOY 231) em uma área irrigada por pivô central, derivado de imagens multiespectrais obtidas por VANT e do índice CWSI calculado a partir da relação TCARI/SAVI, com valores variando de 0 (sem estresse, tons de azul) a 1 (alto estresse, tons de vermelho). As linhas radiais e a circunferência representam a geometria do pivô, enquanto os quadrados identificados como TRT1–TRT5 indicam as parcelas experimentais com diferentes lâminas de irrigação, permitindo comparar a resposta da cultura a cada tratamento. A distribuição espacial do CWSI evidencia que áreas associadas ao tratamento TRT4 apresentam valores mais elevados, indicando déficit hídrico localizado mesmo sob a mesma estratégia operacional do equipamento, o que não seria capturado por medições pontuais de solo ou clima. Esse tipo de mapeamento aéreo permite identificar faixas e setores com aplicação insuficiente de água ou com maior demanda evapotranspirativa, subsidiando o diagnóstico de falhas de uniformidade e o ajuste fino das lâminas recomendadas por setor do pivô. Dessa forma, a etapa de aquisição aérea integra a solução tecnológica como módulo de sensoriamento de alta resolução, traduzindo a

heterogeneidade espacial do talhão em um indicador quantitativo de estresse hídrico que alimenta os módulos de análise e controle subsequentes.

A Figura 4, também adaptada de Zhang et al. [4], mostra o mesmo talhão em uma data posterior, já no estágio de maturação (DOY 240), destacando a evolução temporal do estresse hídrico e sua interpretação sob a ótica da arquitetura de controle do sistema. O disco irrigado é segmentado em setores angulares e faixas radiais que correspondem a zonas de manejo do pivô central, e as parcelas TRT1–TRT5 funcionam como unidades de calibração para o módulo de decisão, que associa a cada zona um nível médio de CWSI. A partir desse campo espacial de estresse, o sistema pode recalcular a velocidade de avanço do pivô ou a vazão dos emissores em ciclos subsequentes, aumentando a aplicação nos setores com CWSI mais alto (vermelho) e reduzindo-a nas zonas já bem supridas de água (azul). Integrado à plataforma em nuvem e aos sensores instalados no equipamento (pressão, vazão, posição angular), esse componente transforma o mapa em uma camada operacional da solução tecnológica, fechando o ciclo entre medição remota, processamento de dados e atuação automática. Assim, a imagem ilustra como o sistema proposto utiliza a informação espacial e temporal do estresse hídrico para suportar decisões de irrigação em nível de sub-setor do pivô, aproximando o manejo da condição real da cultura em campo

E. Segurança

Embora o foco da metodologia esteja na integração dos dados e no desempenho agrônomo, a segurança da comunicação entre drones, pivôs e a plataforma em nuvem também é tratada de forma cuidadosa. Na arquitetura proposta, canais criptografados (TLS) são utilizados em protocolos como MQTT e HTTPS, em conjunto com mecanismos de autenticação forte (por exemplo, certificados digitais, chaves de API ou *tokens*), garantindo a integridade e a autenticidade tanto dos dados quanto dos comandos transmitidos [14, 15, 16].

Além disso, são adotadas medidas complementares, como assinatura ou verificação de integridade das mensagens de comando, registro de *logs* para auditoria e validações adicionais realizadas pelo próprio pivô antes da execução. Esses recursos ajudam a prevenir alterações indevidas, comandos maliciosos ou erros operacionais. Assim, mesmo não sendo o foco central do estudo, essa camada de proteção garante um nível sólido de segurança, suficiente para mitigar os principais riscos associados ao uso de IoT em sistemas de irrigação de precisão.

IV. CONCLUSÃO E PESQUISAS FUTURAS

A. Resultados

Neste trabalho foi apresentada uma arquitetura integrada para detecção de estresse hídrico em lavouras irrigadas por pivô central, estruturada a partir de uma rede veicular de drones, módulos de monitoramento instalados nos equipamentos de irrigação e uma plataforma de processamento em nuvem. Considerando o cenário da agricultura brasileira e a necessidade de reduzir perdas de produtividade associadas à baixa uniformidade de aplicação de água [2], a proposta organiza de forma

clara todo o fluxo de aquisição de dados, análise e atuação, aproximando o diagnóstico das condições hídricas do campo de um processo quase em tempo real.

Os resultados conceituais indicam que a integração de imagens RGB, multiespectrais e termais obtidas por VANTs com dados operacionais dos pivôs (posição angular, velocidade, pressão e vazão) permite estimar, em cada setor irrigado, tanto a lâmina efetivamente aplicada quanto o estado hídrico da cultura. Essa abordagem está alinhada a pesquisas recentes em sensoriamento remoto e mapeamento de estresse hídrico em sistemas irrigados [17, 18]. Ao combinar esses produtos com indicadores de uniformidade e princípios de irrigação de precisão, a arquitetura proposta contribui para identificar setores sub ou superirrigados, orientar ajustes de velocidade e lâmina aplicada, e reduzir desperdícios de água e energia [19].

Do ponto de vista tecnológico, o estudo reforça tendências atuais de integração entre IoT, redes sem fio de longo alcance, telemetria de pivôs e análise inteligente de dados no ambiente agrícola [12, 14, 15]. A incorporação de mecanismos de segurança incluindo comunicação criptografada, autenticação forte e registros de auditoria mostra que é possível evoluir de arquiteturas experimentais para soluções mais robustas e alinhadas às recomendações de proteção de dados para sistemas agrícolas conectados [12, 14]. Em síntese, a principal contribuição deste trabalho é a apresentação de um arcabouço de referência que integra sensoriamento remoto, telemetria e inteligência computacional em um ciclo contínuo de monitoramento, diagnóstico e intervenção [3, 4, 15]. Esse arcabouço é voltado à melhoria da uniformidade de irrigação em pivôs centrais e ao uso sustentável da água em sistemas agrícolas irrigados.

B. Desafios

Apesar do potencial identificado, a implementação prática da arquitetura proposta ainda enfrenta desafios técnicos e operacionais relevantes. Embora o estudo apresente uma metodologia detalhada, faltam experimentos de larga escala em áreas comerciais com múltiplos pivôs e diferentes culturas. A transição do modelo conceitual para validações em campo exige lidar com a variabilidade real de *layouts* de pivôs, topografia, tipos de emissores e estratégias de manejofatores reconhecidos como determinantes para a uniformidade de irrigação e para o desempenho produtivo das culturas [2].

No uso de drones, persistem limitações relacionadas à autonomia de voo, às restrições regulatórias, às condições atmosféricas durante as janelas de aquisição e à necessidade de calibração rigorosa dos sensores ópticos e termais. Esses elementos são essenciais para garantir comparabilidade temporal dos índices de vegetação e estresse hídrico [18]. A execução de missões frequentes sobre diversos pivôs, especialmente em momentos críticos do ciclo da cultura, também impõe demandas logísticas, de planejamento e de manutenção que podem dificultar a escalabilidade da solução em propriedades de grande extensão.

Quanto à infraestrutura de comunicação e processamento, integrar dados provenientes de drones, controladores de pivô, sensores de solo e estações meteorológicas requer enlaces confiáveis, de baixa latência e um sistema capaz de organizar,

armazenar e analisar grandes volumes de dados de forma oportuna [14, 15, 19]. Em áreas rurais, onde a conectividade frequentemente é limitada, torna-se necessário combinar diferentes tecnologias de comunicação (LoRa, redes celulares, satélite) e adotar estratégias capazes de manter a operação mesmo diante de falhas.

Por fim, embora indispensáveis, os mecanismos de segurança adicionam complexidade ao processo. A gestão de certificados, chaves de acesso e perfis de usuário demanda capacitação técnica e práticas claras de governança da informação. Além disso, equilibrar a proteção dos dados operacionais dos produtores com a possibilidade de compartilhamento seguro para pesquisa e melhoria contínua representa um desafio transversal em sistemas de irrigação de precisão [12, 14].

C. Propostas Futuras

Como desdobramentos naturais deste estudo, destacam-se diversas frentes promissoras de pesquisa e desenvolvimento. A primeira envolve a implementação de protótipos da arquitetura em áreas comerciais com pivôs centrais, permitindo avaliar, ao longo de uma ou mais safras, o impacto real da solução sobre a uniformidade de aplicação de água, o consumo hídrico e energético e a produtividade das culturas. Esses experimentos, comparados ao manejo convencional de irrigação, devem considerar diferentes tipos de emissores, variações de relevo e cenários de disponibilidade hídrica, possibilitando quantificar tanto os ganhos potenciais quanto as limitações da abordagem em contextos produtivos diversos [2, 17].

Uma segunda linha de avanço reside no aprimoramento dos módulos de análise de dados. A incorporação de técnicas de aprendizado de máquina pode permitir previsões mais assertivas de demanda hídrica, recomendações automáticas de lâmina e detecção precoce de anomalias nos padrões operacionais dos pivôs. A combinação de séries temporais de sensores, índices de vegetação e variáveis meteorológicas tende a favorecer o desenvolvimento de sistemas de apoio à decisão mais autônomos, capazes de ajustar o manejo de irrigação considerando metas de produtividade, restrições de água e cenários climáticos futuros [12, 14, 15, 19].

Do ponto de vista da comunicação e da infraestrutura, há espaço para explorar arquiteturas híbridas que integrem redes de longo alcance e baixa potência, como LoRa, com enlaces NB-IoT ou LTE-M. A avaliação de diferentes topologias conectando módulos do pivô, estações base e drones, atuando como nós móveis, pode contribuir para maior resiliência da rede em campo [12]. Também são relevantes estudos sobre mecanismos avançados de segurança e confiabilidade, como detecção de intrusão, verificação distribuída da integridade de comandos e o uso de criptografia leve adequada a dispositivos com recursos limitados [12, 14].

Por fim, recomenda-se expandir o escopo da abordagem para além do estresse hídrico, incorporando variáveis agrônomicas complementares, como estado nutricional, presença de pragas e doenças e informações hidrológicas em escala de bacia. A integração de dados de múltiplas fontes e diferentes escalas de observação pode impulsionar o desenvolvimento de plataformas mais completas de agricultura de precisão. Assim, a proposta deixa de se limitar ao controle de pivôs centrais e passa a

apoiar a gestão integrada da água e da produtividade em sistemas agrícolas complexos, contribuindo para a sustentabilidade do uso dos recursos naturais e para a segurança alimentar [14, 18, 19].

REFERÊNCIAS

- [1] Elisio Contini e Adalberto Aragão. *O Agro Brasileiro alimenta 800 milhões de pessoas*. URL: <https://www.gov.br/pt-br/noticias/agricultura-e-pecuaria/2021/03/participacao-brasileira-saltou-de-us-20-6-bilhoes-para-us-100-bilhoes/populacao-alimentada-pelo-brasil.pdf> (acesso em 30/06/2024).
- [2] Dong-yu Cai, Hai-jun Yan e Lian-hao Li. “Effects of water application uniformity using a center pivot on winter wheat yield, water and nitrogen use efficiency in the North China Plain”. Em: *Journal of Integrative Agriculture* 19.9 (2020), pp. 2326–2339. DOI: 10.1016/S2095-3119(19)62877-7.
- [3] Dong-yu Cai, Hai-jun Yan e Lian-hao Li. “Effects of water application uniformity using a center pivot on winter wheat yield, water and nitrogen use efficiency in the North China Plain”. Em: *Journal of Integrative Agriculture* 19.9 (2020), pp. 2326–2339. DOI: 10.1016/S2095-3119(19)62877-7.
- [4] Liyuan Zhang, Huihui Zhang, Yaxiao Niu e Wenting Han. “Mapping Maize Water Stress Based on UAV Multispectral Remote Sensing”. Em: *Remote Sensing* 11.6 (2019). DOI: 10.3390/rs11060605.
- [5] Dimosthenis C. Tsouros, Seferina Bibi e Panagiotis Sargiannidis. “Unmanned Aerial Systems for Agriculture—A Review”. Em: *Drones* 4.3 (2020), p. 41. DOI: 10.3390/drones4030041.
- [6] Hao Dong, Jiahui Dong, Shikun Sun, Ting Bai, Dongmei Zhao, Yali Yin, Xin Shen, Yakun Wang, Zhitao Zhang e Yubao Wang. “Crop water stress detection based on UAV remote sensing systems”. Em: *Agricultural Water Management* (2024). DOI: 10.1016/j.agwat.2024.109059. URL: www.elsevier.com/locate/agwat.
- [7] Manish Yadav, B. B. Vashisht, Niharika Vullaganti, Prem Kumar, S. K. Jalota, Arun Kumar e Prashant Kaushik. “UAV-enabled approaches for irrigation scheduling and water body characterization”. Em: *Agricultural Water Management* 304 (2024), p. 109091. DOI: 10.1016/j.agwat.2024.109091. URL: <https://doi.org/10.1016/j.agwat.2024.109091>.
- [8] B. S. Acharya, N. Acharya e G. Kharel. “Unmanned Aerial Vehicles in Hydrology and Water Resources: A Review”. Em: *Hydrology* 8.3 (2021), p. 149. DOI: 10.3390/hydrology8030149. URL: <https://doi.org/10.3390/hydrology8030149>.
- [9] L. S. Santana et al. “Analysis of Sprinkler Irrigation Uniformity via Multispectral Drone Imagery”. Em: *Water* 6.10 (2025), p. 268. URL: <https://www.mdpi.com/2673-4117/6/10/268>.
- [10] Imran Ali Lakhari, Aneela N. Laghari, Abdul Bari Somro et al. “A Review of Precision Irrigation Water-Saving Technology: From Concept to Practices”. Em: *Agriculture* 14.7 (2024), p. 1141. DOI: 10.3390/agriculture14071141. URL: <https://www.mdpi.com/2077-0472/14/7/1141>.
- [11] AGWAN e Digital Matter. *SensorNode LoRaWAN® for Pivot Irrigation Monitoring with AGWAN*. Case study. Acessado em: DD Mês AAAA. 2021. URL: <https://www.digitalmatter.com/case-studies/pivot-irrigation-monitoring-with-agwan>.
- [12] G. S. P. Lakshmi et al. “Intelligent IoT sensor-coupled precision irrigation model based on LoRa and machine learning”. Em: *Smart Agricultural Technology* (2022). DOI: 10.1016/j.smate.2022.100256. URL: <https://doi.org/10.1016/j.smate.2022.100256>.
- [13] A. K. Caetano et al. “Low-cost LoRa-based IoT system for automated irrigation in smallholder farming”. Em: *Anais do Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais (WCAMA)*. Sociedade Brasileira de Computação, 2025. URL: <https://sol.sbc.org.br/index.php/wcama/article/view/36079>.
- [14] Mansoor Ali e [outros autores]. “Integration of smart sensors and IoT in precision agriculture: trends, challenges and future perspectives”. Em: *Frontiers in Plant Science* 16 (2025), p. 1587869. DOI: 10.3389/fpls.2025.1587869.
- [15] Junfeng Gao, Xin Zhang, Dongping Wang e Xi Yang. “Towards smart agriculture with internet of things and artificial intelligence”. Em: *Biosystems Engineering* 190 (2020), pp. 156–168. DOI: 10.1016/j.biosystemseng.2019.12.004.
- [16] B. Lakshmi e S. G. Kumar. “IoT-based smart irrigation system with real-time detection over LoRa”. Em: *Journal of Intelligent & Fuzzy Systems* 45.4 (2023), pp. 7613–7626. DOI: 10.3233/JIFS-221735.
- [17] Liyuan Zhang, Huihui Zhang, Yaxiao Niu e Wenting Han. “Mapping Maize Water Stress Based on UAV Multispectral Remote Sensing”. Em: *Remote Sensing* 11.6 (2019), p. 605. DOI: 10.3390/rs11060605.
- [18] Hao Dong, Jiahui Dong, Shikun Sun, Ting Bai, Dongmei Zhao, Yali Yin, Xin Shen, Yakun Wang, Zhitao Zhang e Yubao Wang. “Crop water stress detection based on UAV remote sensing systems”. Em: *Agricultural Water Management* 303 (2024), p. 109059. DOI: 10.1016/j.agwat.2024.109059.


- [19] Imran G. Lakhier, Nazim Lakhier, Muhammad A. Chandio e Sheeraz M. Shah. “Advances in Efficient Irrigation Techniques: A Comprehensive Review”. Em: *Water* 16.1 (2024), p. 94. DOI: 10.3390/w16010094.

AUTORES



Eduardo Costa Resende concluiu o Ensino Médio no Colégio Universitário de Aplicação. Graduado em Engenharia de Software pelo INATEL - Instituto Nacional de Telecomunicações. Mestrando em Engenharia de Telecomunicações com ênfase em Inteligência Artificial pelo INATEL - Instituto Nacional de Telecomunicações. Desenvolvedor de

Software Embarcados Júnior e QA de sistemas fim a fim na empresa Soil Tecnologia. Tem interesse nas áreas de Software Embarcado, Computação Gráfica, Ciência de Dados e Inteligência Artificial.



Paulo Otavio Luczensky de Souza concluiu o Ensino Médio no Colégio Agostiniano Mendel. Graduado em Engenharia de Computação pelo INATEL - Instituto Nacional de Telecomunicações. Mestrando em Engenharia de Telecomunicações com foco em Inteligência Artificial pelo INATEL - Instituto Nacional de Telecomunicações.

Trabalha como Cientista de Dados Júnior na empresa Jump Label. Tem interesse nas áreas de Análise de Dados, Ciência de Dados e Inteligência Artificial.